

Язык Python для анализа данных


Лекция 6

Описательная статистика. Повторение.

Описательная статистика

Определение и цель

- Описательная статистика занимается сбором, обработкой, представлением и анализом данных.
- Основная цель описательной статистики - резюмировать данные так, чтобы их можно было легко интерпретировать. Одними из ключевых показателей являются **среднее**, **медиана** и **мода**, которые помогают понять центральную тенденцию данных.



Среднее (Mean)

- **Среднее арифметическое** - это сумма всех значений, деленная на их количество. Оно показывает «среднее» значение данных и чувствительно к выбросам.

Пример: Даны числа

1, 2, 3, 4, 5, 6, 7, 8, 9

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5 + 6 + 7 + 8 + 9}{9} = 5$$

среднее арифметическое

Формула среднего арифметического:


$$\bar{x} = \frac{\sum x_i}{n}$$

где:

- x_i – отдельные значения выборки,
- n – количество значений в выборке.

Выбросы/Посторонние значения (outliers)

- **Выброс/постороннее значение (outlier)** — это точка данных, которая выходит за рамки общей картины набора данных и существенно отличается от других наблюдений.



Выбросы/Посторонние значения (outliers)

Пример


- Набор данных: 1, 2, 4, 6, 8, 3, 1000, 9, 12, 158, 10

Выбросы 1000 и 158.

Выбросы/Посторонние значения (outliers)

Причины появления

- Ошибки ввода данных
- Изменчивость выборки
- Ошибки измерения
- Настоящие аномалии



Медиана (Median)

- **Медиана** - это значение, которое делит упорядоченный набор данных на две равные части. Если количество значений нечетное, медиана - это центральное значение. Если четное - медиана находится как среднее двух центральных значений.
- **Алгоритм нахождения медианы:**
 1. Упорядочить данные по возрастанию.
 2. Найти центральное значение.
 - Если количество элементов **нечетное**, медиана - это средний элемент.
 - Если **четное**, медиана - это среднее двух центральных элементов.

Медиана (Median)

- **Пример:**

- Для чисел 3, 4, 5, **7**, 8, 9, 11 медиана равна 7 (средний элемент в упорядоченном массиве при нечетном количестве элементов).
- Для чисел 1, 3, 4, **5, 7**, 8, 9, 12 медиана равна $(5+7)/2 = 6$. (среднее арифметическое двух центральных элементов в упорядоченном массиве при четном количестве элементов)

Медиана менее чувствительна к выбросам по сравнению со средним. Имеет смысл для ранговых и количественных переменных, но не для качественных.

Мода (Mode)

- **Мода** - это наиболее часто встречающееся значение в наборе данных. Возможны три случая:
 - Одна мода (мономодальное распределение).
 - Две моды (бимодальное распределение).
 - Более двух мод (мультимодальное распределение).

Мода (Mode)


- Пример:

- В наборе данных 2, **3**, **3**, 4, 5, 5, 6, 6, 7, 7, 8, 2, **3** мода равна 3, так как это значение встречается чаще всего.
- В данных 1, 1, **2**, **2**, **2**, **3**, **3**, **3**, 4, 5, 4 моды = 2 и 3 (бимодальное распределение).


Мода особенно полезна для анализа категориальных данных (например, самый популярный тренд, товар, еда и т. д.).

Если все значения в распределении встречаются одинаково часто, то такая выборка не имеет моды.


Унимодальное



Бимодальное




Мультимодальное



Сравнение среднего, медианы и моды

Показатель	Определение	Чувствительность к выбросам	Когда использовать
Среднее	Средняя величина данных	Высокая	Когда данные распределены нормально
Медиана	Центральное значение в отсортированном ряду	Низкая	Когда есть выбросы или асимметричное распределение
Мода	Самое частое значение	Низкая	Для категориальных данных или определения модального класса

Сравнение среднего, медианы и моды



Мода, медиана и среднее СОВПАДАЮТ для симметричного унимодального распределения. К появлению перекоса чувствительнее всего среднее значение.

Метрики центральной тенденции

- Они показывают, вокруг каких значений концентрируются данные.
- **Среднее арифметическое (Mean)** - показывает «типичное» значение.
- **Медиана (Median)** - полезна при наличии выбросов, так как не зависит от экстремальных значений.
- **Мода (Mode)** - наиболее часто встречающееся значение, важно в дискретных данных.

Применение в ML:

Используется для проверки баланса данных (например, классов в задаче классификации).

Размах (Range)

Размах - это разница между максимальным и минимальным значением в наборе данных.

Формула:

$$Range = X_{max} - X_{min}$$

Пример:

Если даны числа 3, 3, 7, 2, 9, 5, 2, 5, 8, 6, 10, то размах:

$$10 - 2 = 8$$

Размах показывает разброс данных, но чувствителен к выбросам.

Дисперсия (Variance)

Дисперсия измеряет, насколько сильно данные отклоняются от среднего.

Формула:

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

Чем больше дисперсия, тем сильнее разброс данных.

Стандартное отклонение

Standard Deviation

Стандартное отклонение - это квадратный корень из дисперсии. Оно показывает, насколько типичные значения отклоняются от среднего.

Формула:

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}}$$

Чем больше стандартное отклонение, тем больше разброс данных.

Метрики разброса (дисперсия и отклонение)

- Они показывают, насколько сильно варьируются данные.
 - **Размах (Range)** - простейший показатель разброса
 - **Дисперсия (Variance)** - средний квадрат отклонений от среднего.
 - **Стандартное отклонение (Standard Deviation)** - корень из дисперсии, показывает типичное отклонение данных от среднего.
-  **Применение в ML:**
Если разброс данных велик, может потребоваться нормализация или стандартизация (например, StandardScaler в sklearn).

Нормализация

Нормализация - это процесс преобразования данных в единую шкалу, чтобы избежать влияния различных диапазонов значений. Она помогает улучшить качество моделей машинного обучения и повышает точность вычислений.

Зачем нужна нормализация?

- Устраняет различие в масштабах данных
- Повышает точность моделей машинного обучения
- Ускоряет процесс обучения
- Улучшает интерпретируемость результатов

Методы нормализации

1. Min-Max нормализация: $X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$

```
from sklearn.preprocessing import MinMaxScaler  
  
scaler = MinMaxScaler()  
X_scaled = scaler.fit_transform(X)
```

- Переводит значения в диапазон [0,1] или [-1,1]
- Чувствительна к выбросам Когда распределение данных далеко от нормального.


2. Z-score стандартизация: $X_{stand} = \frac{X - \mu}{\sigma}$

```
1 from sklearn.preprocessing import StandardScaler  
2  
3 scaler = StandardScaler()  
4 X_scaled = scaler.fit_transform(X)
```

- Среднее значение = 0, стандартное отклонение = 1
- Подходит для данных с нормальным распределением

Методы нормализации

```
import numpy as np  
X_log = np.log1p(X)  #  $\log(1 + X)$ 
```



3. Логарифмическое преобразование: $X_{log} = \log(X + 1)$

- Уменьшает влияние выбросов
- Применяется к данным с высокой асимметрией

4. Нормализация по квантилям (RobustScaler):

- Применяется к данным с выбросами
- Использует медиану и межквартильный размах

Метрики для описания данных

- Коэффициент вариации (Coefficient of Variation, CV)
- Квартили (Quartiles)
- Межквартильный размах (IQR - Interquartile Range)
- Коэффициент асимметрии (Skewness)
- Эксцесс (Kurtosis)

Коэффициент вариации

Coefficient of Variation, CV

Измеряет относительный разброс данных, выражается в процентах. Это помогает при отборе признаков: иногда удаляют признаки с чрезмерно высоким CV, если они не несут полезной информации.

Формула: $CV = \left(\frac{s}{\bar{x}} \right) \times 100\%$


Чем выше CV, тем больше изменчивость данных.

Если CV целевой переменной очень мал, задача может быть почти тривиальной (мало вариации → модель может просто предсказывать среднее).

Если CV очень велик, задача сложная — модель должна улавливать широкий диапазон значений.

```
import numpy as np
```

```
data = np.array([10, 12, 14, 15, 18])  
cv = np.std(data, ddof=1) / np.mean(data)  
print(f"CV: {cv:.3f} ({cv*100:.1f}%)")
```






Квартили

Quartiles

Разделяют данные на 4 равные части.

- **Q1 (первый квартиль)** - 25% данных ниже этого значения.
- **Q2 (медиана)** - 50% данных ниже.
- **Q3 (третий квартиль)** - 75% данных ниже.
- **Пример:**
Если данные: 2, 4, 6, 8, 10, то:
 - $Q1 = 3$
 - Медиана ($Q2$) = 6
 - $Q3 = 9$



Межквартильный размах

IQR - Interquartile Range

Разница между третьим и первым квартилями:

$$IQR = Q3 - Q1$$



Используется для выявления выбросов (outliers): значения, выходящие за диапазон **$[Q1 - 1.5 * IQR, Q3 + 1.5 * IQR]$** , считаются выбросами.

Коэффициент асимметрии


```
from scipy.stats import skew  
skew_val = skew(data, bias=False)
```

Skewness = 0

Skewness

Показывает, насколько распределение данных **симметрично**.

- **Skewness > 0** - правосторонняя (положительная) асимметрия.
- **Skewness < 0** - левосторонняя (отрицательная) асимметрия.
- **Skewness ≈ 0** - симметричное распределение.



Skewness > 0

Skewness < 0

- Многие алгоритмы машинного обучения (особенно линейные модели, такие как линейная регрессия, логистическая регрессия, а также методы, основанные на расстояниях, например, kNN) чувствительны к распределению признаков.

$$skewness = \frac{(x - \mu)^3}{\sigma^3}$$


Эксцесс

Kurtosis

Измеряет «пикообразность» распределения.

Признаки с высоким эксцессом могут делать модель чувствительной к выбросам, особенно в линейных моделях или методах, основанных на дисперсии.

- **Kurtosis > 3** - распределение с "тяжёлыми хвостами" (острое). можно использовать робастные скалеры
- **Kurtosis < 3** - распределение более плоское.
- **Kurtosis = 3** - нормальное распределение.



$$kurtosis = \frac{(x - \mu)^4}{\sigma^4}$$

```
1 from scipy.stats import kurtosis
2 kurt = kurtosis(data, fisher=True)
```